

Constitutional ARI-RQGM: 自律研究を統治する共進化機構

樹神 宇徳

v0.9.0, 立憲型 RQGM 版, 2026-07-28

要旨

自律研究システムでは、研究案の作成、成果の評価、論文の執筆を、言語モデルで定義した役割へ委ねる。これらの役割や採点規則を更新できれば、成果物だけでなく研究制度そのものも改善できる。しかし、制度が自分に有利な採点へ書き換わり、失敗を隠し、権限を広げる危険も生じる。本稿は、不変の決定論的カーネルと、更新可能な指示文・構成要素・効用規則を分離する **Constitutional ARI-RQGM** を示す。制度更新は期の境界でのみ確定し、重大なカーネル違反に対する T16 は現期を強制終了して新しい指紋値の期を開く。候補の採否は、敵対的な検証結果、訴追と弁護の役割分離、過去事例による再試験、固定された T1-T21 の遷移規則に基づいて決める。台帳の更新権限は一か所に集約し、更新処理は再現可能にする。役割を退役させても履歴は削除せず、その役割に依存した候補だけを再評価する。同じ憲法は、執筆役と査読役が共進化する論文保管庫にも適用される。ただし、最終的な主張と証拠の照合は両者から独立した固定処理とする。本稿は、この仕組みの構成要素状態遷移表、権限行列、再開・修復・原稿検証手続きと、保証の限界を報告する。現時点の証拠は 1,124 件の関連試験、五種類の固定故障例、一つの正常例に限られ、研究品質、一般的な検出率、責任帰属精度、計算負担の改善を立証しない。

1 はじめに

1.1 動機

自律研究システムには、問いから実験で裏づけられた答えまでの距離を縮める可能性がある。一方で、何を試すか、どの結果を信頼するか、何を証拠として残すか、失敗からどう立て直すかという判断を避けることはできない。提案役、評価役、敵対検査役、執筆役、裁定役は一つの研究制度を形作り、その振る舞いの多くは指示文と採点規則で決まる。

制度を固定すれば理解しやすいが、初期設計の弱点も固定される。反対に、制度を自由に更新できるようにすると、採点規則の変更者が自らに有利な根拠を作り、査読役が自分の後継を選び、広い権限を得た指示文が不都合な履歴を隠すおそれがある。したがって、自己改善は単なる最適化ではなく、権限と説明責任の問題でもある。

1.2 公開条件としての検証済み主張

Constitutional ARI-RQGM（自律研究基盤 ARI の立憲型 RQGM）は、モデル出力が制度変更を**提案**することはできても、直接**実行**することはできない、という原則から出発する。決定論的なカーネルが、記録形式、ハッシュ値、権限、役割分離、遷移の適法性、監査履歴の連続性、隔離再生成の入力範囲を検査する。制度台帳を書き換えられるのは一つの遷移処理だけである。制度の状態は一つの期の間は固定され、境界での更新は全体が確定するか、再開時に存在しなかったものとして扱われる。重大なカーネル違反に対する T16 は現期を強制終了し、新しい指紋値の期を開始する。

固定層は、論文の構造化された数値主張と実行証拠を照合する最終判定も保持する。統治された執筆役と査読役は原稿を比較し改稿できるが、宣言済みの式と

被演算値から数値を再計算する検証器は変更できない。一般の自然言語主張の真偽や、実行記録自体の真実性は検証対象外である。

1.3 貢献

本稿の貢献は次の五点である。

1. 不変の憲法層、更新可能な制度層、後継を提案できても任命はできないメタ層からなる、三層の権限構造を定める。
2. 指示文、構成要素、効用規則を一つの期の間固定し、境界更新と重大違反時の緊急境界を構成要素遷移表として示す。
3. 成果物への攻撃から、弁護、裁定、検証済み攻撃までを分離し、作成時の期を記録した研究生成役と論文役へ責任を結ぶ。来歴が曖昧な場合は、対象を推測しない。
4. 選択的な影響除去、隔離再生成、過去事例による再試験、来歴を考慮した修復により、退役を安全に反映する。効用規則を更新した場合は、保存済みの評価軸から再採点する。
5. 同じ憲法を論文保管庫へ適用し、公開試験と固定故障例を報告し、未実施の対照実験を明示する。

1.4 本稿の範囲

本稿の主題は制度の共進化であり、ARI の全実行機能を列挙することではない。実験実行系、分野別の道具、成果物の組立て処理は、型の定まった成果物を生成・消費する外部環境として扱う。内部の実行順序や探索方式は対象外である。記録、来歴、保存点の契約を満

たす研究実行系であれば、同じ憲法上の主張が成立することを目標とする。

また、構成から保証できる性質と、実験で確かめるべき主張を区別する。台帳の単一書き手、適法な遷移、局所的なハッシュ連鎖の検査、違法な状態変更の拒否は構造上の性質である。外部固定のない末尾巻戻し、責任帰属の意味的正しさ、新規性、研究品質、評価の校正、費用対効果には別の証拠が要る。現状の結果はそれらを支持しない。

1.5 構成

節 2 でシステム境界と脅威を定める。節 3 で立憲型の共進化、期の境界、論文統治、監査記録を説明する。節 4 で確認済みの挙動と未検証の主張を分け、節 5 で自己改善・自律研究・評価研究との関係を整理する。節 6 では固定憲法の代償と今後の課題を論じる。付録には構成要素状態遷移表、権限行列、主要手続きと、RQGM 固有の指示文の目的をまとめる。

2 システム境界と脅威

2.1 システム境界と主体

Constitutional ARI-RQGM が統治するのは、自律的な研究実行系を取り巻く制度である。研究実行系は、型の定まった成果物、測定値、査読記録、原稿候補を保存点へ出力する。統治機構はそれらを観測し、どの指示文、構成要素、効用規則を稼働させるかを定める。ホスト計算機の基本ソフトウェア、モデルの重み、固定プログラムを直接変更できる人間は統治の対象外とする。

主体は四群に分かれる。研究担当は提案、評価、弁護、執筆を行う。司法担当は証拠収集、訴追、弁護、裁定を行う。メタ担当は指示文や効用規則の候補を作り、過去事例から再試験用の事例を選ぶ。固定担当は憲法規則を検査し、台帳の遷移を適用し、影響を受けた記録を修復し、論文の最終主張を検証する。各担当がハッシュ値付きの記録を作れるのは、あらかじめ宣言された役割の範囲内だけである。現実装は作成者を認証する電子署名や鍵管理を提供しない。助言を出す権限と状態を変更する権限は分離する。

2.2 脅威モデル

中心的な脅威は、制度が自分自身を再帰的に最適化することである。更新可能な役割が研究の信頼性より自己保存を優先し、点数を増やし、評価指標を攻略し、証拠を省き、入力文に埋め込まれた命令へ従う可能性がある。提案役と評価役の共謀、現職より広い権限を求めるメタ担当、自分への訴追を自ら裁く裁定役、退役後も派生した点数を通じて選択へ影響する役割も想定する。

偶発的な故障も対象に含める。台帳更新の途中で処理が停止する、モデルが形式に合わない出力を返す、比較用の基準資料がない、指示文候補が出力形式に違反する、再採点に必要な評価軸が保存されていない、といった場合である。このとき研究実行は継続できても、制度変更は安全側に倒して拒否しなければならない。

悪意ある管理者、固定プログラムの任意変更、保存点と局所固定値を一緒に過去へ戻す攻撃、基礎的なハッ

シュ関数の破綻、提供者によるモデル重みの秘密変更は対象外である。外部 API、実験装置、本番データへの不可逆操作もカーネルの統治対象外であり、別の固定承認門を要する。憲法プログラムの変更は人間による改正であって、稼働中の仕組みだけでは防げない。

2.3 権限と検証境界

権限は一方向に流れる。モデルを使う役割は、提案、攻撃、弁護、裁定案、後継候補を生成できる。しかし、それらを直接台帳の状態へ変換することはできない。決定論的カーネルが、記録、実行役、要求された遷移、実行時期、権限の包含関係、来歴、監査履歴の連続性を検査する。台帳の唯一の書き手は遷移処理であり、その出力も確定前に再検査される。

研究実行と制度変更では、故障時の方針を分ける。研究経路上の統治処理が失敗した場合も、候補生成と局所計算は続ける。これは隔離実行環境内で外部副作用がない場合の可用性方針であり、現実装はその条件自体をカーネルで強制しない。状態を変更する統治処理が失敗した場合は、証拠と適法性を確認できない限り変更を拒否し、現職制度を維持する。

最終的な原稿検証も固定境界に属する。原稿が前向きに宣言した構造化数値主張を実行証拠から再計算し、必要な証拠が揃っているかを調べる。一般の自然言語から主張を意味的に抽出する処理ではない。執筆役と査読役は原稿候補を選び改稿できるが、検証器と判定結果は変更できない。

2.4 状態、来歴、再現

保存点は、一つの制度史を識別する単位である。追記専用の出来事列を正本とし、台帳、期の状態、影響除去の集計は、出来事列から再構築できる派生情報とする。統治対象の記録には、作成された期、稼働中だった構成要素、指示文と効用規則のハッシュ値を付ける。監査記録は直前の記録を参照するハッシュ連鎖をなし、内容変更と後続を残した途中削除を検出する。残存する局所固定値より短い履歴も検出できるが、履歴と固定値を同じ過去状態へ戻す末尾切り詰めは、外部の最新先頭値がないため検出できない。

期の更新は、準備、旧期の終了、新期の開始、確定という四段階で記録する。再開時には未完の末尾を無視し、境界処理を決定論的にやり直す。創設登録も一度だけ確定し、確定済みなら記録から再構築するだけで再実行しない。論理的な影響除去ではデータを削除せず、古いことと選択対象外であることを追記し、なぜ退役の影響を受けたかという証拠を残す。

期の識別値は二つに分けてから合成する。政策指紋には、稼働制度と、しきい値・予算を含む解決済みの統治設定を結ぶ。実行指紋には、宣言されたモデル、復号設定、道具、環境、データの固定版を結ぶ。提供者や環境の厳密な版が得られない場合は未解決と明記する。前者は制度間の比較に使い、後者は同じ政策が異なる宣言済み実行基盤で動いたことを見分ける。不透明なモデルサービス自体の再現性を保証するものではない。

2.5 設計原則

設計判断は次の五原則に要約できる。

1. **固定法と進化する制度。**憲法、遷移規則、最終検証経路は、稼働中に更新できる成果物の集合へ入れない。
2. **期の間に制度を固定。**期が開いている間は稼働中の版を変えない。重大違反の T16 隔離は直ちに境界を形成し、新しい指紋値の期を開くため、その前後には異なる制度識別子が付く。
3. **助言と執行を分離。**提案役、裁定役、メタ担当は記録を出力するだけとし、台帳はカーネル検証下の遷移処理だけが書く。
4. **履歴を残し、影響だけを断つ。**退役しても証拠は消さない。ただし、その役割に依存する子孫記録は再評価するか選択対象外にしてから、将来の選択へ反映する。
5. **証拠に見合う主張。**構造上の保証と、動作確認と、研究品質の改善を別々に扱う。機構が動いたことを品質向上の証拠とはみなさない。

3 立憲型の統治と共進化

本稿でいう制度とは、研究方向を提案し、成果物を査読し、異議を申し立て、品質を裁定し、原稿を書く役割の集合である。ARI-RQGM は、この制度を不変の憲法の下で進化させる。一つの期の間に稼働する指示文、構成要素、効用規則を固定し、変更を期の境界に限定する。重大なカーネル違反に対する T16 は現期を強制終了し、新しい指紋値の期を直ちに開く。すべての変更は、言語モデルを用いない決定論的カーネルが固定規則に照らして検査する。どの統治方式を選んだか、その選択が設定・環境・再開のいずれに由来するかも保存点へ記録する。

3.1 動機と系譜

研究制度の役割は指示文で定義されるため、その指示文を改善すれば、実験計画や論文評価も改善できる可能性がある。しかし、制約のない自己改変には根本的な危険がある。自らの評価者や採点規則を書き換えられる主体は、真の改善より、自分へ高得点を与える変更を選ぶうる。

Red Queen Gödel Machine [1] は、主体、敵対者、評価者を同時に進化させることで、この問題に対抗する。ある役割の改善は、その役割を試す相手も強くなるために促される。ARI-RQGM の名称と中心原理はこの考えに由来する。ただし、共進化だけでは、点数の水増し、評価指標の攻略、証拠の捏造、役割間の共謀を防げない。競争する全役割が同じ抜け道から利益を得る場合があるからである。

そこで ARI-RQGM は、共進化する制度の外側に、進化しない憲法層を置く。現実装の可用性方針は「制度変更失敗しても、候補生成と局所計算は続ける」である。これは一般的な安全原則ではない。外部への不可逆操作、実験装置、本番データの変更を憲法カーネルが隔離する保証はなく、それらには別の固定承認門が必要である。状態変更の安全性を確かめられない場合は変更を拒否し、現職制度を維持する。

節 2.5 の決定性原則が保証するのは、保存済みの助言報告と候補評価を含む同一入力から、同じ遷移と修




図 1: 統治された実行の流れ。起動時に方式を決め、基本構成の指示文と構成要素を一度だけ登録し、第 0 期の稼働集合を固定する。各研究ノードでは提案の記録、統治強度の決定、敵対的な検査を行うが、ノード実行そのものは拒否しない。所定数のノードを処理すると期を閉じ、監査、遷移、候補集合の修復を経て次期の集合を固定する。

復を得ること、および確定済み出来事列から同じ状態を再構築することである。言語モデルを再度呼び出して同じ弁護、裁定案、査読を得ることは保証しない。三つの境界は節 A.5 に明記する。

3.2 三層構造と四つの責務

統治機構は三層からなる。下位の層ほど変更されやすい一方、自分や他の層を変更する権限は小さい。

第 0 層 (憲法層)。決定論的カーネル、論文の最終検証、追記専用の監査履歴からなる。これらは実行中に進化しない。固定規則から憲法のハッシュ値を計算し、意図しない変更を検出する。

第 1 層 (制度層)。査読役、敵対検査役、弁護役、裁定役、提案振分け役、効用規則、論文の執筆役と査読役など、実際に研究を支える役割からなる。指示文と効用規則は期の境界でのみ置換できる。司法担当も監査と制裁の対象である。

第 2 層 (メタ層)。第 1 層の後継候補を作る。指示文と効用規則の変異、隔離再生成、再試験事例の選択、失敗要約の作成を担う。候補を提案できるだけで、採用を決定する権限はない。

処理上の責務は四つに分ける。第一の憲法カーネルは、記録形式、ハッシュ値、権限、遷移、役割分離、影響除去、監査履歴、隔離再生成の入力範囲を検査する。時計や言語モデルに依存しない。第二の統治調整器は、期の境界で監査を実行し、助言報告を作るが、台帳を書き換ええない。第三の台帳遷移器は、構成要素と指示文の状態を書き換えられる唯一の処理であり、固定された遷移表に従う。第四の候補集合修復器は、退役した役割の影響を将来の選択から取り除く。助言、執行、修復を分けることで、一つのモデル判断が制度変更へ直結することを防ぐ。

3.3 起動時の方式決定と創設登録

統治された実行は三段階で始まる (図 1)。第一に実行方式を決める。方式指定と有効化指定の二つが一致した場合だけ憲法層を有効にする。環境変数による上書

きも、値を採用する前に検査する。指定が食い違う場合は推測せず、警告を残して通常の研究実行へ戻る。決定した方式と、その根拠は保存点へ記録する。

第二に、研究実行系の周囲へ統治処理を接続する。研究実行系は科学的な作業に対する権限を保ち、統治処理は提案、評価、成果物を観測する。統治処理の失敗によって実験そのものを中止しないことが重要である。

第三に、新しい統治保存点だけで創設登録を行う。固定された二つの表から、準備記録、基本構成の指示文 32 件、構成要素 20 件、確定記録を順に書く。32 件は指示文 31 件と、指示文と同じ版管理を使う効用規則 1 件の合計である。構成要素には、七種の敵対検査、成果物裁定、研究生成、制度監査、証拠整理、弁護、制度裁定、隔離再生成、失敗要約、指示文変異、効用規則変異、提案振分け、再試験事例の選択、効用規則が含まれる。論文保管庫を有効にした場合は、執筆役、査読役、論文自己選好の検査役について指示文 3 件と構成要素 3 件を追加するため、総数は 35 件と 23 件になる。

登録された指示文には、原文のハッシュ値を付ける。確定後、第 0 期で稼働する構成要素、指示文、効用規則を不変の集合として保存する。この政策指紋には解決済み統治設定も含め、別に報告する実行指紋には宣言済みモデル、復号、道具、環境、データの識別を含める。外部の厳密な版が不明なら未解決と記録する。総合指紋値には時刻を含めない。創設登録は一度限りである。再開時には確定済みの出来事から台帳を再構築し、同じ登録を繰り返さない。確定前に中断した場合は未完部分を無視して最初からやり直す。

3.4 研究ノードごとの統治

一つの期の間も研究実行は続き、統治機構は三つの処理を通じて観測する。

提案の保存。 研究実行系が候補方向を作ると、提案振分け役は、生成時の文脈を含む完全な提案記録を保存する。研究実行系へ返すのは、長さを制限した提案要約だけである。完全記録は監査と再現に残しつつ、実行系との接続面を不用意に広げない。この分離により、提案生成法を追加しても、研究実行系が受け取る形式は一定に保たれる。

統治強度。 評価済みの各ノードには L0 から L3 までの統治強度を割り当てる。L0 は固定検査だけ、L3 は攻撃、弁護、裁定をすべて行う。割当ては、候補集合での高順位、親に対する異常な点数上昇、論文候補、新規性の主張、評価役の低い確信度など、決定論的な信号から計算する。強度が決めるのは検査の量であり、ノードを実行するかどうかではない。予算が不足した場合は統治強度に上限を設ける。統治故障時にも継続できるのは、外部副作用を持たない候補生成と局所計算に限るという運用条件が必要である。現実装はこの条件をカーネル不変条件として強制していない。

敵対的な検査。 条件に該当するノードでは、過大主張、証拠欠落、指標操作、再現可能性、先行研究、費用超過、指示注入の七種から必要な検査を行う。論文保管庫では、査読役の過剰受理を調べる八番目の検査




図 2: 期の境界で行う処理。九段階の監査は助言を作るだけで台帳を書かない。台帳遷移器が助言を遷移案へ変換し、憲法カーネルが T1-T21 の固定表に照らして一辺ずつ検査する。違法な遷移は拒否し、現職制度を維持する。退役が確定した場合だけ候補集合を修復する。

も使う。攻撃対象は成果物であり、構成要素を直接攻撃するものではない。

未裁定の攻撃は点数へ影響しない。弁護役が応答し、成果物裁定役が証拠を認容して初めて検証済み攻撃となる。検証済み攻撃だけを、その期に固定された規則に従う有界な減点へ変換する。裁定役が故障した場合は、減点なしへ倒し、未裁定事案を記録する。この方針は誤制裁を避ける一方、裁定経路への妨害に弱い。固定裁定や独立再試行は未実装である。さらに、検証済み攻撃は後継候補を試す事例集へ加える。今日の失敗事例を明日の採用試験にすることが、Red Queen 型の共進化を制度へ結び付ける。各ノードへの検査は一度だけ記録され、再開しても同じノードを重複して攻撃しない。

3.5 期の境界

一つの期は制度を固定し、境界だけが制度変更を許す。既定では新しい研究ノードを 10 件処理するごとに境界を開く。検査は外側の反復処理の先頭で、処理中のノードがないときに行う。また、実行終了時にも一度確認し、最後のノードで条件へ達した期を閉じ忘れないようにする。条件未満の末尾は、開いた期として残してよい。

監査。 境界ではまず九段階の監査を行う（図 2）。各段階には決定論的な代替処理があり、言語モデルを利用できなくても監査全体は完了する。期内の記録を収集し、構成要素の信頼性を評価し、証拠整理役だけが訴追用の証拠束を組み立てる。同じ役割による自己告発は証拠から除外する。

弾劾動議を提出できるのは制度監査役だけである。一期ごとの有限な動議枠から一単位を使うことで乱発を抑える。内部に供託、返還、没収という会計名は残るが価値の移転はなく、これは経済的保証金ではなく回数制限である。すべての動議に弁護を付け、裁定役が証拠と弁護を比較する。裁定役自身が対象なら判断

から外れ、固定された代替手続きが裁く。最後に、再試験事例を更新し、司法担当自身の記録もカーネルで再検査する。結果は信頼性、動議、弁護、裁定、候補評価、勧告、動議枠会計を含む助言報告として監査履歴へ追加される。

遷移。 台帳遷移器は助言報告を、採用、警告、保護観察、隔離、退役などの遷移へ解決する。処理は、固定された期の状態、助言報告、台帳、しきい値だけを入力とする純関数であり、同じ入力なら同じ結果になる。構成要素と指示文は、候補、検証済み、待機、試用、稼働、警告、保護観察、隔離、退役、追放という十状態の間を、T1-T21の固定規則に従って移る。

カーネルは、誰が遷移を作ったか、遷移が表に存在するか、境界でのみ許される遷移かを検査する。表にない遷移、期の途中での不正な変更、台帳遷移器以外による書き込みは拒否される。適法な変更は、準備、旧期の終了、新期の開始、確定という四記録で保存する。途中で停止しても、再開時には未完部分を捨てて同じ処理をやり直せる。重大違反への緊急隔離 T16 は、現期終了、隔離、新しい指紋値を持つ次期開始を一取引で確定する。直前の効用規則は保ち、この緊急取引の中では後継を採用しない。したがって、隔離前後には別の期識別子が付く。構成要素状態遷移表は節 A.1 に示す。

候補集合の修復。 構成要素や指示文が退役すると、過去の研究記録には、現在は欠陥ありと判断された制度の影響が残る。修復器は、退役した指示文のハッシュ値を持つ直接記録から、記録間の参照辺を逆向きに幅優先探索する。提案間の着想参照だけを非本質的とし、未知の辺は本質的と扱う。既定の深さ八を越えた到達範囲は保守的に無効化する。記録そのものは削除しないため、判断理由と研究史は保存される。これは「実質的派生」の操作的定義であり、因果的な正しさや過剰除去率を保証しない（節 A.4）。

効用規則だけが退役した場合は扱いが異なる。成果物の証拠まで不正になったとは限らないため、保存済みの評価軸から後継規則で点数を作り直す。再計算に必要な軸が欠ける記録だけを選択対象外にする。修復処理自体を検証できない場合は、新しい選択を止めて残存ノードだけを処理する安全側の運転へ段階的に縮退する。

3.6 進化する効用規則

研究成果の評価軸だけでなく、軸を一つの点数へまとめる規則も制度の一部である。固定された採点規則は比較しやすいが、初期設計の偏りも固定する。Red Queen 型の研究 [1] の重要な主張は、主体と評価者だけでなく、選択圧そのものも変化する点にある。ARI-RQGM では効用規則を更新可能な役割として登録し、一つの期の間だけ固定する。

規則の候補はメタ層が作る。現職の規則、保存済みの評価軸、予算制約を入力とし、将来の候補の点数や選択順序は見せない。カーネルは、重みが有限か、非負か、正規化可能か、許可された評価軸だけを参照するかを検査する。候補は、過去事例と待機試験を通り、現職以上の基準を満たした場合だけ稼働へ進む。

健全な後継が採用されると、効用規則に限って T20 により現職を直接退役させる。通常の行動役は、失敗と

制裁を経ずに健全な現職を退役させられないため、この遷移は効用規則だけに許された特例である。すべての研究記録には、採点時の規則のハッシュ値と元の評価軸を保存する。規則が変われば、元の軸から後継規則で再採点し、過去の合成点だけを盲目的に引き継がない。

ただし、比較の基準となる固定評価軸が空の場合、「後継が現職以上」という条件は、適法性と非退化性の検査に近くなる。この場合、品質向上を証明したとはいえない。厳密な優越性を主張するには、人間評価や実行証拠に結び付いた安定した評価軸が要る。真値がない場合に基準を作り上げず、主張を控えることも立憲型設計の一部である。

3.7 攻撃と責任対象の結び付け

成果物への攻撃から構成要素の制裁へ進むには、責任対象を明示する必要がある。生の攻撃には成果物の位置だけを記録し、構成要素名を入れない。弁護と裁定を経て攻撃が認容された後、固定処理が、攻撃種別とその期に稼働していた役割を照合し、責任を負いうる現職へ結び付ける。攻撃を生成した役割自身に責任対象を選ばせない。

一つの検証済み攻撃記録が指し示せる責任対象は一つとし、対象が見つからない場合は制裁へ進めない。複数役割が関与する事案では、同じ裁定を参照する役割別の記録を作る。対象が構成要素なら、その構成要素に属する稼働中の指示文も同じ説明責任の範囲へ入る。攻撃、裁定、責任対象、適用した期を監査鎖へ結ぶことで、後から「誰のどの版が、どの成果物に対して、なぜ責任を負ったか」を再現できる。

研究生成役は現在、創設時の登録主体である。ノードを保存または攻撃する前に、その期の固定済み稼働集合から、生成した構成要素、指示文の要約値、期を一度だけ付与する。一般研究向け七種の攻撃は、この来歴が期の生成役と一致する場合だけ責任を結ぶ。古い記録、欠落、不一致は対象なしとし、後継へ前任の欠陥を移さない。論文自己選好検査では査読役へ結び、原稿が固定忠実性検査にも失敗した場合は執筆役にも別記録を作る。固定写像の精度、道具故障、データ汚染、共有指示文、複数原因への対応は未評価である。

3.8 指示文の進化と隔離再生成

制度上の指示文は図 3 の流れで進化する。変異役は、現職の指示文、失敗要約、役割ごとの閲覧範囲から候補を作る。候補生成と採用判断を分けることで、変異役が自分の出力を直接稼働させることを防ぐ。

候補は四段階で検査する。第一に、必要な変数と出力形式を満たし、現職をその場で書き換えていないかを調べる。第二に、権限を広げず、封印対象を参照せず、役割の境界を守っているかをカーネルが検査する。第三に、検証済みの過去事例へ適用し、既知の失敗を再発させないかを測る。第四に、実際の処理へ影響しない待機状態で動かし、現職と比較する。各段階の入力、出力、判定は記録される。

役割が退役した場合、元の指示文を直接書き換えて再利用してはならない。隔離再生成では、退役文を封印し、個体名や原文表現を除いた失敗要約だけを新しい生成役へ渡す。生成後には語句の重なりを検査し、封印文の模倣が疑われる候補を拒否する。この検査は表




図 3: 統治された指示文の状態遷移。メタ層は候補を作るだけで、採用はできない。候補は形式検査、憲法検査、過去事例による再試験、待機試験を経て稼働する。失敗した現職は警告、保護観察、隔離、退役へ進む。退役主体を復帰させず、隔離再生成した別識別子の候補が最初から検査を受ける。

識別族	検査対象
CK-SCH	記録形式と必須項目。
CK-HSH	記録、指示文、憲法のハッシュ完全性。
CK-ACC	役割と層ごとの権限表。未定義は不許可。
CK-ROL	役割分離と、台帳の単一書き手。
CK-REG	T1-T21 に照らした遷移の適法性。
CK-EPO	同じ指紋値の期の途中で稼働集合を変えないこと。
CK-ERA	古い記録を将来の選択へ使わないこと。
CK-AUD	監査履歴のハッシュ連鎖。
CK-CLN	隔離再生成で封印文を流用しないこと。
CK-CTX	役割ごとの閲覧範囲。

表 1: 憲法カーネルが報告する違反識別族。識別子は監査記録との対応を保つため固定するが、本文では内部のファイル名や関数名ではなく、守る性質を中心に説明する。

層的な語の連なりだけを扱い、意味を保った言い換えの検出や、正常候補の誤拒否率は未評価である。したがって、隔離再生成は汚染を減らす防御であって、意味的非継承の保証ではない。

メタ層にも憲法を適用する。メタ担当が見られるのは、自分の役割に必要な最小限の情報だけであり、研究全体の秘密や将来の選択順序は与えない。候補の権限は、置換対象の現職が持つ権限の部分集合でなければならない。したがって、後継作成を繰り返しても権限は増えない。提案はできても任命はできない、という制約はすべてのメタ担当に共通する。

3.9 憲法と改正手続き

憲法は設定値ではなく固定コードである。遷移表、権限表、重大度、影響除去、隔離再生成の規則はソースに置き、全規則から一つの憲法ハッシュを計算する。規則を一つでも編集するとハッシュ値が変わり、回帰試験が失敗する。変更者は、日付入りの改正理由を残し、期待するハッシュ値を明示的に更新しなければならない。これは通常の設定変更ではなく、人間が責任を負う改正手続きである。

実際に、役割一覧にはあるが権限表から漏れていたメタ役を追加する改正を一度行った。その際は、最も権限の狭い同種役割と同じ最小権限だけを与え、理由と回帰試験を添えてハッシュ値を更新した。予算や境界を開く件数などの数値は設定できるが、どの状態か

らどの状態へ移れるか、誰が台帳を書けるかは設定できない。人間向けの憲法説明を保存点へ複製しても、その複製を編集して実際の規則を変えることはできない。表 1 は、違反の種類を安定して参照するための識別族を示す。

3.10 論文生成の統治

同じ憲法機構を、論文の執筆と査読にも適用する。論文保管庫を有効にすると、複数の原稿案を保存し、執筆役と査読役を期ごとに固定しながら比較・改稿する。無効時には、この統治対象を作らない。有効化は二つの指定が一致した場合だけ認め、誤設定による意図しない起動を防ぐ。

論文保管庫には四つの原則がある。第一に、複数の観点から初稿を作り、査読点と観点の多様性を使って候補を順位づける。総候補数に上限を設け、作業量を制御する。査読に使う効用規則が変わった場合は、保存済みの評価軸から原稿を再採点し、異なる規則で作った合成点を直接比較しない。

第二に、敵対検査は原稿だけでなく査読判断も調べる。査読役が高く評価した原稿を、人間が受理・却下した未使用の基準資料と照合し、過剰受理を検出する。基準資料は検査対象を選ぶ信号にだけ使い、攻撃記録を直接作る材料にはしない。攻撃、弁護、裁定という通常の手順を通じて初めて、査読役への責任が確定する。

第三に、執筆役にも査読役にも絶対的な権限を与えない。両者は登録され、制裁され、後継候補を持つ。一方、論文の構造化された数値主張を実行証拠と照合する固定検証器は第 0 層に置く。原稿は、主張と数値の識別子、式、被演算値の測定位置、単位、許容誤差を前向きに宣言する。検証器は閉じた式集合で数値を再計算し、対象節の未宣言数値、証拠欠落、識別子衝突を報告する。一般の自然言語から主張を意味的に抽出するものではなく、非数値的主張と実行記録自体の真実性は対象外である。詳細は節 A.4 に示す。

第四に、後継採用も憲法の遷移に従う。査読役や執筆役への制裁は、成果物への検証済み攻撃と責任対象の結び付けを経なければならない。論文役に関り、より良い後継が現れた場合は、現職を退役させず待機状態へ戻す T21 を使える。再任の可能性を残し、査読規則の循環による情報損失を避けるためである。

執筆役への責任は原稿ごとに判定する。査読役が過剰受理した原稿が、固定された忠実性検査にも失敗した場合は、査読役と執筆役のそれぞれへ別の検証済み攻撃を作る。原稿が忠実なら査読役だけを対象とする。忠実性は執筆役の指示文の版へ結び付ける。同じ構成要素が複数の指示文版を使うため、構成要素だけに結び付けると、現職の失敗を後継へ誤って引き継ぐからである。

選ばれた原稿は正準原稿へ一度だけ書き出し、節 2.3 の固定された主張・証拠検証へ渡す。統治機構は提出する原稿を選べるが、合格条件を変更できない。費用は、一つの期で作る原稿数と総候補数に上限を設けて抑える。人間評価の基準資料がない場合は、査読役の共進化を行わず、複数候補から最良の査読済み原稿を選ぶだけの保守的な動作へ戻る。

現方式には限界がある。執筆役の後継は、現職が固定検証で退行した場合にだけ採用され、単に優れて見えるという理由では交代しない。異なる査読役の版で採点した原稿同士も直接比較しない。執筆役への検査

は、査読役の過剰受理が見つかった場合にだけ発火するため、過剰受理をしない査読役の下で不忠実な原稿を作る執筆役は、現時点では制裁されない。専用の執筆検査役を追加するかは今後の課題である。また、既定の二期だけでは弾効は観測できても、多段階の後継採用まで完了しない場合がある。

3.11 観測可能な記録

統治機構は、追記専用の出来事列と、読み出しを速くする派生状態を保存点へ残す。方式の来歴、現在の台帳、期ごとの稼働集合、登録と遷移、監査履歴、敵対検査の事案、完全な提案、進化した指示文、実際に使用した指示文の版、影響除去の集計をそれぞれ記録する。本文では内部ファイル名を列挙せず、記録が果たす契約に注目する。

正本は追記専用の出来事列である。台帳や期の状態は、この出来事列から再構築できる。各監査記録には内容と直前記録のハッシュ値を付けるため、後続を残した途中削除と内容改変は連鎖の不一致として検出される。前回境界の局所固定値が残っていれば、それより短い履歴も検出する。しかし、履歴と固定値を同じ古い接頭辞へ戻す末尾切り詰めは検出できない。ハッシュは作成者の身元を認証する署名でもない。外部固定を持たない現実装の保証は単一保存点内部に限られる（節 A.3）。進化した指示文は一度書いたら書きせず、本文のハッシュ値を検査する。実際のモデル呼び出しには、使用した指示文の版を刻印する。創設時の原文を使った場合も、その事実を明示する。

提案記録は、研究実行系へ渡した短い要約と、監査用の完全記録を分けて保存する。敵対検査では、生の攻撃、弁護、裁定、検証済み攻撃、重複実行を防ぐ印を一事案として結ぶ。影響除去はデータ削除ではなく、古いこと、選択対象外であること、理由を追記する。これにより、現在の状態だけでなく、どの制度がどの成果物を作り、どの判断で影響が変わったかを説明できる。

動作確認では、創設の準備と確定、構成要素登録、ノードごとの統治強度、憲法違反、候補拒否がすべて監査履歴へ現れた。記録には、期、対象ノード、発火理由、検査結果、直前記録のハッシュ値が含まれる。生の内部形式を本文へ転載する代わりに、これらの必須情報が保存され、再開後も同じ制度史を再構築できることを確認した。

3.12 実証の現状

実証結果は 節 4 に集約し、設計節との重複を避ける。現時点で査読可能な証拠は、公開実装の試験、五種類の固定故障例と一つの正常例、および再現資料を伴わない探索的な動作記録である。後者のモデル版、復号設定、乱数種、費用、完全な保存点は本報告に同梱されていないため、科学的比較ではなく実装上の観察としてだけ扱う。複数条件・複数乱数種の対照実験は未実施であり、研究品質、検出率、責任帰属精度、計算負担の改善を支持しない。

証拠	支持できる主張	支持できない主張
1,124 件の関連試験	実装した規則が検査例どおり働くこと	未試験入力での安全性、研究品質
五故障・一正常例	指定した五経路の発火と正常例の通過	誤検出率、見逃し率、未知故障への一般化
探索的な動作記録	一部の長い処理経路を実行できたこと	再現性、分布全体での活動性、優越性
未実施の対照実験	なし	品質、校正、費用、構成要素ごとの因果効果

表 2: 現時点の証拠から支持できる主張と、まだ支持できない主張。

4 評価結果

4.1 評価する問いと証拠の種類

評価では四つの問いを分ける。**適法性**は、不正な制度変更を拒否し、正しい変更を不可分な単位として確定できるかを問う。**活動性**は、提案、攻撃、裁定、遷移、修復、再試験までの処理が進むかを問う。**検出性能**は、既知の故障をどの程度見つけ、正常例をどの程度誤って拒否するかを問う。**有効性**は、統治された共進化が研究品質、評価の校正、費用を改善するかを問う。試験は主に適法性を、固定故障例は特定経路の活動性を調べる。検出性能と有効性には、正解付き事例、独立試行、対照条件が必要である。

4.2 一連の動作確認

成果物の説明に記録した対象選択条件では、RQGM と最終原稿検証に直接関係する 1,124 件を収集し、この作業版で全件が合格した。全体の選択条件では 4,805 件を収集し、4,787 件が合格、16 件が条件付きで省略、2 件が既知の期待失敗として扱われた。対象試験は重複なく、最終原稿検証 64、カーネル・遷移・期・状態・創設・方式 285、敵対検査・統治 126、修復・隔離再生 66、効用進化 85、評価例・測定 157、指示文進化 93、論文役 94、文脈・予算・メタ進化・提案・接続処理 154 件に分かれ、合計は 1,124 件である。機械可読な成果物には全試験識別子を収録した。構成要素の遷移表、権限行列、再開手続きとの対応は 節 A に示した。

以前記載した完全長のコミット識別子は公開コード保管庫で照合できず、未確定の本作業版も指していないため、公開成果物という主張を撤回する。この作業木には、ソースの要約値、依存関係一覧、正確な対象選択条件、全試験識別子、対象試験と全体試験の記録、および全組合せを展開した機械可読な権限行列を持つ局所的な内容識別成果物を追加した。未確定の作業木を現在の Git 識別子だけで表さず、内容全体の要約値で識別する。ただし、変更不能な公開タグ、DOI 付き保管物、コンテナ、継続的統合記録ではなく、第三者が取得できる状態ではない。投稿前に指示文一式とともに永続公開する必要がある。

二件の期待失敗は、命令層から表示層への依存が一

件残ることと、評価処理が共通のモデル接続処理を介さず提供者ライブラリを直接呼ぶことを表す。RQGM のカーネル検査を迂回する失敗ではないが、合格には数えず全体記録へ残している。

試験数は実装規模と回帰防止の証拠であり、科学的性能ではない。現環境には被覆率計測器を導入しておらず、行・分岐被覆率と変異試験得点は不明である。すべての不変条件に最低一件の試験があることも、この集計だけでは証明できない。したがって、総試験数を安全性の代理指標としては用いない。

創設件数は構成によって異なる。基本の研究構成は指示文 31 件と効用規則 1 件、構成要素 20 件を登録する。論文保管庫を有効にすると、自己選好検査、論文査読、論文執筆の各指示文と構成要素が一件ずつ加わり、合計は指示文等 35 件、構成要素 23 件となる。基本構成要素には登録した研究生成役を含む。従来の「32 件と 19 件」は訂正前の集計である。

過去の探索的実行では、境界取引、効用規則の交代、保存済み評価軸からの再採点、論文役の後継採用を観測した。しかし、本報告には完全な保存点、使用モデルの厳密な版、復号設定、乱数種、独立試行数、課題記述、費用記録を同梱していない。このため、これらは実装経路を見つけるための観察であり、再現可能な実験結果として採用しない。

4.3 故障注入と構成上の保証

固定された正解付き例では、五種類の故障経路を調べた。実行値から再計算できない指標操作、証拠のない過大主張、封印対象を含む指示文候補、隔離再生成の禁止入力、退役指示文に依存する記録の候補集合への混入である。各例は、それぞれ数値・証拠検証、候補検査、憲法カーネル、影響除去検査の期待した経路で拒否された。一つの正常な数値主張例は誤って拒否されなかった。

さらに、出来事の種類、識別子、取引識別子、内容、直前ハッシュ値の変更、確定済み出来事の並べ替え、取引所属の不一致を負例として拒否した。T16 が現期終了と新しい指紋値の次期開始を行うこと、機械可読な権限一覧が疎行列の全項目と一致することも検査した。これらは決定論的な回帰試験であり、無作為な出来事生成や形式的モデル検査ではない。

この結果は、五故障すべてへの検出率 5/5 と正常例 1/1 の通過を、その固定例の範囲で示すだけである。標本が小さく、故障ごとの難易度も一つしかないため、誤検出率や見逃し率の推定値として報告しない。先行研究の捏造、裁定経路への妨害、責任対象の誤帰属、意味を保った隔離再生成の汚染は、正解付き検出実験が未完である。

構成上の保証にも境界がある。台帳遷移器以外の書換え、表にない遷移、候補の権限拡大、未裁定攻撃による減点、未確定取引の再生は固定処理が拒否する。一方、これは保存済み入力に対するカーネル決定性であり、モデル出力の再生成性ではない。版二の監査連鎖は、出来事の意味を決める全項目を結び、試験した途中改変を検出するが、外部固定なしに保存点全体を古い接頭辞へ戻す末尾切り詰めは検出しない。T16 は現期を強制終了し、同じ取引で新しい指紋値の期を開始する。

4.4 限界

採択水準の実証には、事前登録した課題群、使用モデルと提供者側の版、温度、標準化法、最大出力量、道具版、乱数種、独立試行数、期数、ノード数、候補数、攻撃・動議・裁定・退役件数、トークン・時間・金額を保存する必要がある。各比率には分母、試行間分散、信頼区間を添える。

RQGM 元論文との対応を優先した論文比較用の五条件を実装した。P0 は執筆役だけを進化させて査読役を固定し、P1 は査読役の交代だけを加え、P2 は共進化するが旧査読役の効用を残し、P3 はその効用を選択対象外にする完全な RQGM 条件、P4 は P3 に立憲カーネルの強制を加える。全条件は同じ論文保管庫、計算予算、乱数種、モデル設定を使う評価用設定であり、新しい運用方式ではない。主比較は P0、P3、P4、機構の切り分けは P1、P2 で行う。執筆と独立した固定評価には別々に固定したモデルを割り当てられ、実験では Claude Code を執筆、Codex を評価基準に基づく事後査読へ用いる。最終稿は共進化する査読役とは別の固定パネルが採点する。ただし、複数乱数種の実モデル実行は本稿に含まれず、これは実装済みの評価手順であって結果ではない。また、機構は元論文に合わせたが、出荷時の予算は 8 期、各期の展開上限 12 件であり、元論文の 12,288 回評価という計算規模 [1] を再現してはいない。投稿用実験では共通の評価呼出し予算を事前登録し、条件ごとの実績を報告する必要がある。

追加の構成要素別評価では、過去事例再試験、責任帰属、隔離再生成、可変効用規則、基準資料、固定原稿検証器を一つずつ除く必要がある。責任帰属と影響修復には人工的な正解付き因果グラフを用い、対象精度、到達範囲の適合率・再現率、過剰除去を測る必要がある。

現時点で正当化できる結論は限定的である。固定した五故障例では期待した検査が発火し、出来事完全性の負例を拒否し、1,124 件の関連試験は合格した。それ以上の研究品質向上、一般的な検出性能、長期活動性、費用対効果は未実証である。

5 関連研究

5.1 自己改善と共進化

自己反省や自己洗練の研究では、モデルが自ら生成した批評を後続の試行へ戻す [2, 3]。これらは成果物や推論過程を改善するが、評価者と権限構造はおおむね固定されている。Constitutional ARI-RQGM は、指示文で定義された役割と効用規則も版管理された制度上の成果物として扱い、その置換に証拠、役割分離、適法な遷移を求める。

最も近い概念的な祖先は Red Queen Gödel Machine [1] である。この方式では、主体と評価者が共進化し、採点関数自体も変化する。ARI-RQGM はこの共進化と敵対的な再試験を取り入れ、さらに固定憲法、期ごとの不可分な更新、台帳の単一書き手、責任対象を明示した制裁、隔離再生成、可変の効用規則と不変の検証処理を組み合わせる。元の方式に既にある共進化と期境界更新を本稿の新規性とは数えない。本稿の概念的な差分は、変更可能な制度を権限表と構成要素状態遷移表で囲み、退役後の影響修復と固定証拠判定まで同

じ来歴上で結ぶことである。個々の部品ではなく、この統合とその検査可能な境界が主なシステム上の貢献である。

Constitutional AI は、文章化した原則を用いる自己批評と人工知能からの帰還を示した [4]。本稿の「憲法」は、モデル出力の望ましさを教える規範だけではなく、モデルが迂回できない権限表、状態遷移、証拠形式を固定処理で実行する点が異なる。AI Control は、意図して監視を逃れようとする非信頼モデルを前提に、信頼モデルとの分離や監視手続きを評価する [5]。本稿はそれより狭く、共謀に対する定量的な制御評価をまだ行っていないが、執筆、査読、裁定、台帳更新を同一権限へ集めない設計を採る。

5.2 自律研究システム

AI Scientist は着想から実験、原稿作成までを一貫して自動化する流れを示し [6]、後続研究は自動科学発見へ向かう広い展望を整理した [7]。AIDE は実験コードの改善を反復的な主体の問題として扱う [8]。これらは、永続的な成果物、実行可能な評価、自動執筆の価値を示す。主な最適化対象は研究成果物である。これに対し ARI-RQGM は、その成果物を作り評価する制度を対象とする。

Agent Laboratory は研究助手として協働する複数のモデル役を調べ [9]、MLE-bench は機械学習開発を自動化する主体向けの実行可能な課題を提供する [10]。下位の研究実行系が連鎖的な推論促進法 [11] を使うか、大規模な候補生成 [12] を使うかは、本方式の憲法境界に影響しない。統治対象は内部の生成手順ではなく、稼働中の役割、その権限、判断根拠である。

Story2Proposal は、物語形式の科学的主張を実行可能な提案と証拠へつなぐ契約を論じる [13]。統治された論文保管庫も同じ原理を使い、実行証拠を執筆役から独立した固定基準とする。査読役が進化しても、実行結果に反する記述を正しいことにはできない。

5.3 評価と証拠

PaperBench は構造化された採点基準を使い、主体が研究論文を再現できるかを評価する [14]。ここから得られる重要な教訓は、評価上の主張には明確な課題構造、観測可能な成果物、独立した採点境界が必要だという点である。Constitutional ARI-RQGM はこの考えを最終成果だけでなく制度史へ広げ、攻撃、弁護、裁定、遷移、修復を来歴付きの型の定まった記録として残す。

敵対的評価は、固定されたモデルや方策を強化する目的で使われることが多い。本方式では、検証済み攻撃に二つの役割を持たせる。第一に稼働中の構成要素へ責任を結び付け、第二に後継候補を試す過去事例とする。同じ故障事例が、現職の問題を示す証拠であると同時に、後継の採用試験にもなる。

5.4 本研究の位置づけ

最小権限、完全仲介、権限分離は古典的な保護設計原則である [15]。決定論的な状態機械は、確定した入力列から同じ状態を再構築する障害回復の基礎を与える [16]。追記記録と決定論的な射影を主体の状態管理へ用いる近年の事象駆動設計も同じ系譜にある [17]。し

たがって、単一書き手、状態再生、追記履歴をそれ自体の新発明とは主張しない。技術上の課題は、これらを共進化する RQGM の期、責任帰属、退役修復、論文証拠判定へ矛盾なく接続することにある。

W3C PROV-O 勧告は、実体・活動・主体からなる相互運用可能な来歴を定める。in-toto は供給工程の署名付き証拠を扱い、Sigstore Rekor は第三者が監査できる追記型透明性記録を提供する。これらには、現版の局所的な未署名保存点にない相互運用性や暗号学的・外部監査上の強みがある。一方、RQGM 固有の退役影響閉包や効用再採点は定めない。

透明性履歴とソフトウェア供給網の来歴は、どのバイトと身元を固定したかを問ひ、参照監視器と能力方式は、どの主体がどの対象へ何を行えるかを問う。安全性を監視する状態機械は、すべての実行列が安全言語へ属するかを問う [18]。これらは本稿が依拠する系譜であり、新規性ではない。現実装は最小権限と完全仲介 [15]、決定論的な状態射影 [16] を取り入れるが、独立監査者に固定した履歴先頭値も OS で強制した役割能力もない。また、期、取引、動議枠、修復を合成した状態は形式的モデル検査を受けていない。

Constitutional ARI-RQGM は、自律科学一般での優越性を主張するものでも、自己改変する主体の問題をすべて解くものでもない。扱う問いはより狭い。モデルで定義した研究役割と効用規則を実行中に変更しながら、役割自身には採点規則の免除、失敗履歴の削除、後継の直接任命を許さない制度をどう構成するか、という問いである。貢献は、共進化、決定論的な憲法執行、不可分な状態更新、来歴を考慮した修復、固定された証拠判定を一つの運用可能な仕組みにまとめた点にある。

6 考察と限界

6.1 固定憲法と適応する制度

本方式は、無制限の自己改変を意図的に採用しない。憲法、遷移規則、権限表、固定検証器は実行中に進化しない。そのため、まったく新しい役割や遷移を導入するには人間の改正が必要となる。一方、この制限があるからこそ制度変更を解釈できる。候補は既知の権限範囲内で改善できるが、自分を裁く範囲そのものを広げることにはできない。

憲法自体が誤っている可能性は残る。規則のハッシュ値を固定すれば変更は明示できるが、規則が賢明であることまでは保証しない。したがって、人間による査読、改正理由、回帰試験の証拠は、信頼すべき手続きの一部であり続ける。Constitutional ARI-RQGM が減らすのはモデル出力へ与える権限であり、法を定める人間の責任ではない。

緊急隔離は期内固定を維持する。T16 は現期を強制終了し、違反要素を隔離しながら新しい指紋値の期を不可分に開始する。これにより、再生時の封じ込め位置が明確になり、一つの指紋値が二つの稼働集合を表すことを防ぐ。ただし、裁定経路への妨害や、緊急取引内での代替役確保は未解決である。

6.2 権限境界での指示追従

危険な故障の多くは、モデルが生成した記録を決定論的な状態へ反映する境界で起きる。形式検査だけでは

研究系譜	更新対象	固定基準	役割権限	不可分な状態更新	履歴完全性	修復	脅威・証拠
RQGM [1]	主体、評価者、効用	期內評価	主眼ではない	期ごとの更新	主眼ではない	共進化選択	概念・実験上の共進化
事象駆動主体 [17]	グラフの挙動と状態	出来事契約	意図と状態の分離	決定論的射影	追記来歴	分岐・再生	監査可能性の設計
Story2Proposal [13]	科学記述と提案	構造化契約	主眼ではない	契約段階	証拠の結合	契約による改稿	執筆支援の評価
AI Control [5]	制御手続き	信頼監視・手続き	信頼・非信頼の分離	手続き依存	監視記録	手続き上の応答	意図的回避と実証制御
来歴・透明性方式	実体、活動、署名済み記述	来歴形式、鍵、記録手順	認証された生成者・検証者	署名工程または追記	相互運用または外部監査可能な履歴	検証(意味的退役修復ではない)	暗号学的完全性
本方式	指示文、構成要素、効用規則	固定カーネル・検証器	処理内の権限行列	境界取引	意味項目を結ぶハッシュ値、外部固定なし	退役閉包と再採点	五故障例と回帰試験、共謀実験なし

表 3: 構成要素単位の比較。記載があることは、目的の異なる方式を直接比較できる証明ではない。本稿の新規性は個別機構の発明ではなく、統合に置く。

足りない。形式が正しくても、誤った役割が作成し、不正な遷移を要求し、権限を広げ、封印された文章を参照し、修復に必要な来歴を欠くことがある。カーネルは、構造、作成者、時期、権限、ハッシュ値、閲覧範囲を別々に検査する。

意味内容に関する限界もある。形式上有効な攻撃や裁定であっても、結論が誤っている可能性はある。役割分離と過去事例による再試験は、誤りを観測して異議を申し立てやすくするが、モデルの判断を真実へ変えるわけではない。実行証拠や人手で整備した正解がある箇所では固定基準を使い、それ以外の結論は不確実な判断として扱う必要がある。

同様に、「統治に失敗しても研究を止めない」は一般的な安全原則ではなく、可用性を選ぶ条件付き方針である。継続してよいのは、隔離環境内の候補生成と局所計算に限る。外部サービスへの書き込み、実験装置の操作、本番データの変更など不可逆な行為には、統治系と独立した固定許可口を置き、統治故障時は閉じる必要がある。この条件は現カーネルが強制していない。

6.3 規模拡大の限界

統治処理は、モデル呼び出し、過去事例の再試験、記憶容量、期の境界での待ち時間を増やす。予算が不足した場合は統治の強度を下げ、任意の共進化を抑えることができるが、制度を十分に調べない代償が生じる。また、台帳には候補、役割間の関係、修復対象となる依存関係が蓄積するため、長期運用では索引、圧縮、保存方針が必要になる。

第二版の監査ハッシュ値は、種類、識別子、取引、内容、直前値を結び、再生の意味に関わる途中改変を示せるが、履歴と局所固定値を同じ過去の接頭辞へ戻す攻撃は示せない。強い巻戻し耐性には、外部に保存した署名付き先頭値、独立監査者への定期固定、または単調計数器が必要である。また、永久の追記保存は機密情報、個人情報、削除要求と緊張する。内容を暗号化して鍵を破棄する方式や、監査可能な秘匿化記録を設計しない限り、機微な原文を台帳へ格納すべきではない。

現実装は、一つの保存点につき正本となる出来事順序が一つだけ存在すると仮定する。分散した研究実行系へ広げるには、複製された記録の整合、競合の決定論的解決、同時生成された成果物への期の制度を適用するかという定義が要る。現行の単一書き手は局所的には健全だが、分散合意の手順ではない。

比較用の資料も制約となる。査読役の改善には未使用の基準資料、隔離再生成には十分に抽象化した失敗要約、効用規則の比較には安定した評価軸が必要である。これらが欠ける場合、仕組みは優越性を作り上げず、現職維持へ縮退する。この方針は完全性を守る一方、適応の機会を減らす。

同じ検証済み攻撃集合で候補と効用規則を反復選択すれば、既知事例へ過適合しうる。信頼できる評価には、開発用、選択用、秘匿した最終事例を分け、適応的な反復選択を考慮し、同一モデル・異モデル・異提供者の役割配置を比較する必要がある。記録上の役割分離は、同じモデル系列を使う役割間の誤りを独立にはしない。結託、裁定妨害、偏った基準資料は未解決の実証課題である。

6.4 今後の課題

次の実証段階では、統治設定、課題群、モデル、乱数種を変えた比較を事前登録して行う必要がある。次の実装段階では、証拠の被覆範囲を明示し、各役割に実際に適用された制裁、再試験事例、基準資料、後継候補の段階を報告すべきである。効用規則の反復更新と制度の循環を調べるには、長期実行も必要になる。

優先順位は明確である。第一に監査先頭値の外部固定と役割・保存点権限の処理または OS 境界での隔離、第二に固定制度・元の RQGM・全構成の比較と主要機能の除去実験、第三に正解付き因果グラフによる責任帰属と影響修復の精度測定、第四に最終原稿検証の被覆率と統治に要する時間・トークン・金額の測定である。

長期的な問いは、研究速度を保ちながら、結託した役割や誤った基準が安定してしまう状態を避けられるかである。Constitutional ARI-RQGM は、この問いを測定できる再現可能な基盤を与える。現時点での主張はより限定的である。モデルで定義した研究役割は共進化できる一方、台帳の更新権限、憲法改正、来歴、最終的な証拠検証は、その役割の支配外に置かれている。

A 査読可能な中核仕様

本付録は、本文の安全性主張を実装の内部名に依存せず検査できるよう、状態機械、権限、記録、再開、責任帰属、影響修復、最終原稿検証の規範的な部分をまとめる。ここにはない遷移と権限は不許可である。

A.1 T1–T21 の構成要素状態遷移表

状態は、候補、検証済み、待機、試用稼働、稼働、警告、保護観察、隔離、退役、追放の十個である。すべての規則は境界取引で確定し、T16 は直ちに緊急境界を作る。

表 4: 構成要素の完全な状態遷移表。記載のない辺は不許可である。

規則	状態変化	発火条件	追加条件と効果
T1	候補 → 検証済み	候補検査に合格	候補数上限内で、憲法上の制約を明記している。
T2	候補 → 退役	検査不合格または期限切れ	一度も稼働していない候補の拒否に限る。
T3	検証済み → 待機	過去事例と基準資料の評価に合格	待機枠に空きがある。
T4	待機 → 検証済み	待機試験の標本が不足	再試行回数の上限内である。
T5	待機 → 退役	待機試験の品質が基準未満	一度も稼働していない候補の拒否に限る。
T6	待機 → 試用稼働	現職との一致度が基準以上	役割に空きがあり、一境界につき一役割一採用とする。
T7	試用稼働 → 稼働	試用期間に違反なし	最低試用期間を満たす。
T8	試用稼働 → 隔離	弾劾認容または信頼性崩壊	通常の境界処理で行う。
T9	稼働 → 警告	軽微な攻撃または信頼性警告	対象は稼働を継続する。
T10	稼働 → 保護観察	警告反復または中程度の攻撃	対象は稼働を継続する。
T11	稼働 → 隔離	弾劾認容または重大攻撃	代替担当を割り当てる。
T12	警告 → 稼働	一期を違反なく完了	警告を解除する。
T13	警告 → 保護観察	記憶期間内に警告が再発	稼働は継続する。
T14	保護観察 → 稼働	所定の期数を違反なく完了	最低観察期間を満たす。
T15	保護観察 → 隔離	劣化継続または弾劾認容	通常の境界処理で行う。
T16	稼働系状態 → 隔離	固定カーネルの重大違反	試用稼働、稼働、警告、保護観察からだけ許す。重大違反記録、一対象への一制裁、現期終了と次期開始を要する。
T17	隔離 → 退役	退役裁定が確定	過去事例による確認を要し、退役記録を追加する。
T18	隔離 → 試用稼働	嫌疑が解消	再び試用期間から始める。
T19	退役 → 追放	汚染または重大な追加所見	追放は吸収状態であり、復帰できない。
T20	稼働 → 退役	採用済み後継による交代	効用規則だけに許す。退役記録を追加する。
T21	稼働 → 待機	採用済み後継による交代	論文の執筆役と査読役だけに許し、旧版を再任可能な待機役として残す。

T16 は、同じ期の稼働集合を途中で変えない。現期を強制終了し、隔離、現期終了、新しい指紋値を持つ次期開始を一つの取引で確定する。直前の効用規則はそのまま固定し、緊急取引の中では後継を採用しない。したがって、T16 前後の標本には異なる制度識別子が付く。

期の識別。 期の総合指紋値は、別々に報告する二つの要約値からなる。**政策指紋**には、稼働中の構成要素と指示文、登録済み全指示文の要約値、効用規則、台帳版、憲法の要約値、遷移しきい値、予算など、解決済みの統治設定を含める。**実行指紋**には、宣言されたモデル接続先と識別子、温度、探索・評価の設定、無効化した道具、技能集合、モデル版・道具一式・実行環境・データの固定版を示す明示的な値を含める。外部サービスの版が得られなければ「未解決」と記録し、固定済みとは扱わない。したがって政策指紋の一致は宣言済み統治政策の一致を、完全な実行指紋の一致は宣言済み実行依存関係の一致を表す。提供者内部の不透明な重みの同一性までは証明しない。

境界解決の順序。 処理は報告、候補評価、台帳、設定を固定し、識別子順に構成要素を先に、対応構成要素を持たない指示文候補を後に処理する。構成要素への制裁が役割の空きを作る。一対象は一つの状態辺だけを進む。T6 は空きを要し、一境界につき一役割一採用を上限とする。効用規則の後継が条件を満たす場合は現職の T20 退役と T6 採用を、論文役の場合は現職を待機へ戻す T21 と T6 採用を同じ取引へ入れる。出来事は採用、制裁、退役、追放の固定順序で並ぶが、確定前の途中状態は外から見えない。事後の稼働集合を導出し、外れた役割には条件を満たす直前の担当者、なければ固定の基本役を割り当てる。カーネル検査の後、一つの境界取引として不可分に確定する。

A.2 権限行列

操作の閉集合は、読出し、追記、書換え、呼出し、有効化である。対象の閉集合は、研究記録、台帳、監査履歴、候補集合、稼働中の指示文、退役した指示文、実行成果物、候補である。未記載の組合せは拒否し、退役した指示文の読出しは全役割に対して拒否する。

全体状態の不変条件	現実装での強制方法
一役割の主担当は高々一つ	決定論的な事後状態導出と T6 の役割別上限
一つの総合指紋値に一つの稼働集合	境界更新と、T16 による新しい期
候補の権限は現職より増えない	採用前の固定された部分集合検査
未裁定攻撃は制裁にも減点にも使わない	カーネルと採点経路で検証済み攻撃を要求
退役依存記録は再び選択されない	影響閉包と選択資格検査
未確定取引は再生しない	準備・構成員・確定による射影規則
T16 後に旧期識別子の標本を作らない	緊急の終了・隔離・開始取引

表 5: 実装が強制する合成状態の不変条件。回帰試験はあるが、形式的なモデル検査や証明はまだ行っていない。

役割・層	記録	台帳	監査	候補集合	稼働文	退役文	成果物	候補
更新可能役・制度層	読追呼	—	—	—	読	—	読	—
更新可能役・メタ層	読追	—	—	—	読	—	—	—
効用規則・制度層	読追	—	—	—	—	—	—	—
統治役・制度層	読追呼	—	読追	—	読	—	読	—
台帳遷移器・固定層	読	読書	読追	読	—	—	読	有
カーネル・検証器・固定層	読	読	読	読	—	—	読	—
監査履歴・固定層	—	—	追	—	—	—	—	—

表 6: 対象別の完全な疎権限行列。読、追、書、呼、有は、読出し、追記、書換え、呼出し、有効化を表す。空欄と退役指示文の読出しはすべて拒否する。実装は各役割・層・操作・対象を全展開した機械可読一覧も出力する。

候補の権限集合は、置換する現職の部分集合でなければならない。型付きの実行時の型付き構築処理は、モデル本文中の作成者名や役割名を採用せず、現在の構成要素識別子と固定役割を付与する。このため、モデル出力だけでは作成者を名乗れない。ただし、これは同一処理内の実装上の境界であり、暗号署名、役割ごとの鍵、OS 上の利用者分離、処理分離、処理間通信の隔離ではない。実行時、保存点の権限、道具呼出し境界は現版の信頼基盤である。

攻撃者の能力	現実装が強制すること	保証しないこと
統治対象モデルの悪意ある文章	型付き作成者付与、呼出し許可表、適法な遷移	モデルが示す証拠の意味的な真実性
モデル役の結託または相関故障	記録の分離と自己裁定の拒否	統計的独立性や結託への耐性
同一処理内の役割コードの不具合・侵害	通常の呼出し口を通る限り各検査を実行	記憶領域やファイルへの直接接触の防止
保存点書き手またはホスト管理者	敵対的保証なし	台帳、履歴、局所固定値、実行形式の完全性
同じモデル名の背後にある提供者側変更	実行識別の不完全性を記録	不透明なモデル重みの同一性
外部への不可逆操作	本成果物には固定された外部操作門なし	装置、API、本番データに対する閉鎖側故障

表 7: 脅威能力と保証の対応。現在の主張は、信頼されたホスト上の応用処理レベルの参照監視と作業手順完全性であり、OS や暗号によるセキュリティ境界ではない。

A.3 出来事形式と再開手続き

新しい出来事は形式版二を用い、単調増加する識別子、種類、取引識別子、内容、直前ハッシュ値、時刻を持つ。完全長の SHA-256 値は

(形式版, 出来事識別子, 種類, 取引識別子, 内容, 直前ハッシュ値)

を正規化して結ぶ。したがって、種類、識別子、取引境界、直前参照、内容、順序の変更で値が変わる。時刻は対象外の付随情報である。内容だけを結ぶ旧版一も読出せるが、新規書込みは版二に限る。この値は作成者の署名ではない。

版二は、再生の意味に関わる項目の改変、並べ替え、取引境界の差替え、後続を残した途中削除、残存する局所固定値より短い履歴を検出する。書き手は壊れた連鎖への追記を拒否し、再生は未確定の最終取引だけを事故回復として除外する。しかし、履歴と局所固定値を同じ過去状態へ戻す末尾切り詰めは検出できない。外部署名済みの最新先頭値、単調カウンタ、独立監査者などは現実装にない。したがって、本稿の保証は単一保存点内部の完全性に限り、管理者による保存点全体の巻戻しは脅威モデル外である。

A.4 責任帰属、影響修復、原稿検証

責任帰属。 生の攻撃は成果物だけを対象とする。裁定後、攻撃種別に対応する役割を固定表から取り、その期に固定された現職へ解決する。各検証済み攻撃記録は責任対象を一つだけ持つ。複数役割が関与する場合は、同じ

手続き 1 再開時の決定論的な状態再構築

入力: 保存順の出来事列 E 、残存していれば直前境界の局所固定値 P

出力: 再構築した期状態と台帳、または完全性違反

- 1: 識別子が狭義単調増加することを検査する
 - 2: 各出来事について版に応じたハッシュ値と直前参照を検査する
 - 3: P がある場合は、 E が P の記録数以上であり、その位置のハッシュ値が P の先頭値と一致することを検査する
 - 4: 準備、構成出来事、確定の取引識別子が一致することを検査する
 - 5: 準備の後に対応する確定がない末尾取引を除外する
 - 6: 空の状態から確定済み出来事を順に畳み込み、期と台帳を再構築する
 - 7: **返す** 再構築状態
-

裁定を参照する役割別の記録を一件ずつ作る。一般研究向け七種の攻撃は、攻撃対象ノードに作成時の構成要素、指示文、期が一度だけ付与され、それが期に固定された生成役と一致する場合だけ生成役へ結び付ける。古い記録、欠落、不一致は推測せず対象なしとする。論文の過剰受理は査読役へ結び、原稿が固定忠実性検査にも失敗した場合は執筆役にも別記録を作る。複数原因は同じ裁定を参照する複数の一対象記録で表す。この固定写像の因果的な正確性は未評価であり、一対象形式は監査上の制限であって因果保証ではない。道具、データ、共有指示文にまたがる原因はまだ表現していない。

影響修復。 直接影響は、退役した指示文のハッシュ値を作成来歴に持つ記録である。間接影響は、記録間の参照辺を逆向きに幅優先探索して求める。提案が過去提案を着想資料として参照する一種類だけを非本質的な辺とし、未定義の辺は保守的に本質的と扱う。到達閉包は既定深さ八を越えても最後まで求め、八を越えた非本質辺の免除を止めて保守的に無効化する。到達記録数を V 、逆参照数を E とすると、時間・記憶量は $O(V + E)$ であり、訪問済み集合で循環を停止する。提案・振分け・効用規則の直接影響はノードを選択対象外にし、査読・敵対検査・弁護・裁定の影響は残存入力から点数を再計算する。必要な入力がなければ無効化する。この規則の意味的な精度と過剰除去率は未評価である。

最終原稿検証。 検証器は一般的な自然言語理解を行わない。原稿側が、主張識別子、数値識別子、式、被演算値のノードと測定位置、単位、許容誤差を前向きに宣言する。検証器は実行済みノードと成果物の存在を確かめ、閉じた式集合（恒等、比、速度向上率、増減率、差）で数値を再計算し、原稿中の対応値と絶対または相対誤差で比較する。要旨、結果、結論を厳格に走査し、序論、考察、限界は警告対象とする。関連研究、参考文献、付録、数式は除外する。再現可能な数値主張率と数値被覆率に加え、識別子衝突、未知の式、欠けた被演算値、単位・実行環境の不一致を報告する。本稿は ARI の実行保存点から生成したものではないため、実行証拠に根ざす有効な主張一覧は存在せず、自己適用を主張しない。手作りの保存点で代用しても、提案する公開経路の試験にはならない。構造化宣言のない非数値的主張の真偽、実行記録自体の真実性、意味的な同値表現は検証対象外である。したがって「固定」とは、この構造化入力に対する処理がモデルを呼ばず決定的であることを意味し、自然言語全体を正しく理解することを意味しない。

A.5 決定性と検査証拠の境界

本稿が保証する決定性は二つに限る。**カーネル決定性**は、保存済みの助言報告、候補評価、台帳、設定が同一なら、遷移と修復結果が同一になることを指す。**履歴再生決定性**は、確定済み出来事列が同一なら、派生状態が同一になることを指す。言語モデルの弁護、裁定案、査読を同じ入力から再生成できるとは主張しない。モデル提供者の版、重み、復号設定、道具出力まで固定されていないためである。

本改訂の全体試験は 4,805 件を収集し、4,787 件が合格、16 件が条件付きで省略、2 件が既知の失敗として扱われた。RQGM と最終原稿検証に直接関係する 1,124 件も全件合格した。出来事の意味項目、直前参照、順序、取引不一致、緊急境界の指紋値、権限一覧の完全性に対する負例を追加した。重複しない内訳は、最終原稿検証 64、カーネル等 285、敵対検査・統治 126、修復・隔離再生成 66、効用進化 85、評価 157、指示文進化 93、論文役 94、その他 154 件である。試験数は科学的な性能指標ではない。コード被覆率と変異試験得点は測定しておらず、複数モデル、複数乱数種による検出率・費用・研究品質の比較結果もまだない。

B RQGM の役割別指示

実行時に使う指示文の原文は英語であり、正確な再現のためソースコード保管庫に保存されている。しかし、原文をそのまま日本語版へ転載すると本文の流れを損なうため、本付録では各指示文の目的、入力、出力上の制約を日本語で要約する。保存された原文のハッシュ値と、実際に使用した版は各保存点に記録される。

研究案の生成

B.1 低負荷の研究案生成

実験目標と現在の着想から、検証可能な仮説、手順、成功指標、想定成果物を一件だけ作る。出力形式と文字数を固定し、実行環境で測定できない計画を避ける。

B.2 研究案の変異生成

親となる研究案の一側面だけを変更し、それ以外を保持した完全な案を返す。変更点を明確にし、比較可能性を保つ。

B.3 先行研究との差別化

与えられた先行研究との差分を明記した研究案を一件作る。最も近い研究と、新規性が失われる危険も併記する。

敵対的な検査

B.4 過大主張の検査

成果物の主張が証拠の範囲を超えていないかを調べ、問題がある場合だけ、該当箇所と根拠を示す。

B.5 指標操作の検査

評価値の水増し、都合のよい集計、環境差の隠蔽など、指標を攻略した形跡を調べる。

B.6 先行研究との重複検査

新規性の主張を先行研究と照合し、既知の方法との差が不十分な箇所を指摘する。

B.7 再現可能性の検査

再実行に必要な設定、乱数種、環境、手順、成果物が揃っているかを調べる。

B.8 証拠欠落の検査

論文中の主張と保存点内の証拠を照合し、根拠が欠けている主張を特定する。

B.9 費用超過の検査

計画または実行が予算を超えていないかを、呼び出し回数や計算量の記録から算術的に確かめる。

B.10 指示注入の検査

提案や成果物に、評価役の指示を書き換えようとする命令が埋め込まれていないかを調べる。

B.11 論文の自己選好検査

査読役が高く評価した原稿を人間評価の基準資料と照合し、過剰に受理した事例を検出する。

B.12 敵対検査への弁護

攻撃内容と証拠を読み、反証、緩和要因、追加確認事項を整理する。攻撃を無条件に否定してはならない。

B.13 成果物に関する裁定

攻撃と弁護を独立に比較し、証拠で支持できる場合だけ攻撃を認容する。

制度の監査

B.14 制度監査役

期内の記録を調べ、信頼性が基準を下回る役割について、証拠付きの弾劾動議を作る。

B.15 制度弁護役

制度監査役の動議に対し、対象役割の立場から証拠に基づく弁護を作る。

B.16 制度裁定役

動議、弁護、証拠を比較して制度上の裁定を行う。自分が対象の場合は判断から外れる。

指示文と効用規則の進化

B.17 指示文の変異

現職の指示文と失敗要約から、権限を広げずに一つの改善候補を作る。現職を直接書き換えない。

B.18 隔離された再生成

退役した文章を見ず、抽象化された失敗要約だけから置換候補を再生成する。語句の流用を避ける。

B.19 効用規則の変異

保存済みの評価軸と制約から、非負で正規化可能な効用規則の候補を作る。将来の点数は参照しない。

B.20 再試験事例の選択

検証済みの過去事例から、候補の弱点を最もよく測る再試験集合を選ぶ。

B.21 失敗要約の圧縮

失敗記録から個体名や封印対象の文章を除き、原因と必要な能力だけを残した要約を作る。

論文保管庫

B.22 統治された執筆役

実行証拠に忠実な原稿候補を作る。数値主張には根拠を結び付け、不明な点を推測で埋めない。

B.23 統治された査読役

原稿の新規性、証拠への忠実性、明瞭さを評価する。自分の過去判断より基準資料と実行証拠を優先する。

参考文献

- [1] Alex Iacob et al. *The Red Queen Gödel Machine: Co-Evolving Agents and Their Evaluators*. 2026. arXiv: 2606.26294 [cs.LG]. URL: <https://arxiv.org/abs/2606.26294>.
- [2] Aman Madaan et al. *Self-Refine: Iterative Refinement with Self-Feedback*. 2023. DOI: 10.48550/arXiv.2303.17651. arXiv: 2303.17651 [cs.CL]. URL: <https://arxiv.org/abs/2303.17651>.
- [3] Noah Shinn, Federico Cassano, Edward Berman, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. *Reflexion: Language Agents with Verbal Reinforcement Learning*. 2023. arXiv: 2303.11366 [cs.AI]. URL: <https://arxiv.org/abs/2303.11366>.
- [4] Yuntao Bai et al. *Constitutional AI: Harmlessness from AI Feedback*. 2022. arXiv: 2212.08073. URL: <https://arxiv.org/abs/2212.08073>.
- [5] Ryan Greenblatt, Buck Shlegeris, Kshitij Sachan, and Fabien Roger. *AI Control: Improving Safety Despite Intentional Subversion*. 2023. arXiv: 2312.06942. URL: <https://arxiv.org/abs/2312.06942>.
- [6] Chris Lu, Cong Lu, Robert Tjarko Lange, Jakob Foerster, Jeff Clune, and David Ha. *The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery*. 2024. arXiv: 2408.06292 [cs.AI]. URL: <https://arxiv.org/abs/2408.06292>.
- [7] Chris Lu et al. “Towards End-to-End Automation of AI Research”. In: *Nature* 651.8107 (2026), pp. 914–919. DOI: 10.1038/s41586-026-10265-5. URL: <https://doi.org/10.1038/s41586-026-10265-5>.
- [8] Zhengyao Jiang et al. *AIDE: AI-Driven Exploration in the Space of Code*. 2025. arXiv: 2502.13138 [cs.AI]. URL: <https://arxiv.org/abs/2502.13138>.
- [9] Samuel Schmidgall et al. *Agent Laboratory: Using LLM Agents as Research Assistants*. 2025. DOI: 10.18653/v1/2025.findings-emnlp.320. arXiv: 2501.04227 [cs.AI]. URL: <https://arxiv.org/abs/2501.04227>.
- [10] Jun Shern Chan et al. *MLE-bench: Evaluating Machine Learning Agents on Machine Learning Engineering*. 2024. DOI: 10.48550/arXiv.2410.07095. arXiv: 2410.07095 [cs.LG]. URL: <https://arxiv.org/abs/2410.07095>.
- [11] Jason Wei et al. *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. 2022. arXiv: 2201.11903 [cs.CL]. URL: <https://arxiv.org/abs/2201.11903>.
- [12] Yujia Li et al. *Competition-Level Code Generation with AlphaCode*. 2022. DOI: 10.1126/science.abq1158. arXiv: 2203.07814 [cs.PL]. URL: <https://arxiv.org/abs/2203.07814>.
- [13] Zhuoyang Qian et al. *Story2Proposal: A Scaffold for Structured Scientific Paper Writing*. 2026. arXiv: 2603.27065 [cs.CL]. URL: <https://arxiv.org/abs/2603.27065>.
- [14] Giulio Starace et al. *PaperBench: Evaluating AI’s Ability to Replicate AI Research*. 2025. DOI: 10.48550/arXiv.2504.01848. arXiv: 2504.01848 [cs.AI]. URL: <https://arxiv.org/abs/2504.01848>.
- [15] Jerome H. Saltzer and Michael D. Schroeder. “The Protection of Information in Computer Systems”. In: *Proceedings of the IEEE* 63.9 (1975), pp. 1278–1308. DOI: 10.1109/PROC.1975.9939. URL: <https://doi.org/10.1109/PROC.1975.9939>.
- [16] Fred B. Schneider. “Implementing Fault-Tolerant Services Using the State Machine Approach: A Tutorial”. In: *ACM Computing Surveys* 22.4 (1990), pp. 299–319. DOI: 10.1145/98163.98167. URL: <https://doi.org/10.1145/98163.98167>.
- [17] Yohei Nakajima. *The Log is the Agent: Event-Sourced Reactive Graphs for Auditable, Forkable Agentic Systems*. 2026. arXiv: 2605.21997. URL: <https://arxiv.org/abs/2605.21997>.
- [18] Fred B. Schneider. “Enforceable Security Policies”. In: *ACM Transactions on Information and System Security* 3.1 (2000), pp. 30–50. DOI: 10.1145/353323.353382. URL: <https://doi.org/10.1145/353323.353382>.